Para responder a tus dudas de manera clara y rigurosa para tu trabajo de grado, abordemos cada uno de los puntos clave:

---

1. ¿Entrenar a nivel individual (3.4M filas) o agregado por departamento (198 filas)?

Debes usar definitivamente el dataset agregado por departamento (panel_departamento_anio_unido.csv de 198 observaciones).

Hay tres razones metodológicas y teóricas de peso:

1. **Alineación con tus objetivos:** El Objetivo General y el **Objetivo 3** dicen explícitamente: *"Diseñar un modelo predictivo de aprendizaje automático **a nivel departamental**..."*. Tu unidad de análisis es el departamento-año, no el estudiante.
2. **Nivel de agregación del IPM:** El DANE calcula el IPM a nivel departamental. Si usaras los 3.4 millones de registros individuales, tendrías a 100.000 estudiantes de un departamento compartiendo exactamente el mismo valor de IPM en un año. Esto genera un problema grave de **pseudo-replicación** y correlación intraclúster (violando supuestos de independencia en modelos estándar).
3. **Coherencia con los Objetivos 2 y 4:** El Objetivo 2 plantea modelos de panel (departamento-año) y el Objetivo 4 propone simular escenarios de reducción del IPM departamental. Usar 198 observaciones es el enfoque correcto.

---

2. Corrección crítica en tus modelos propuestos

Revisando tu lista de modelos:

- ⚠ **Regresión Logística con ElasticNet: Corrección urgente.** La regresión *logística* se usa para predecir variables categóricas o binarias (clasificación: ej. 0 o 1). Tu variable objetivo (prom_punt_global) es continua (puntaje de 0 a 500, que en promedios oscila entre 200 y 300 aprox.). Debes usar **Regresión Lineal con regularización ElasticNet** (ElasticNet en scikit-learn).
- **Random Forest Regressor:** Excelente opción.
- **XGBoost Regressor (con regularización):** Muy buena opción.

Advertencia para el modelado con

N=198*N*=198

:
Al tener 198 observaciones, modelos basados en árboles como Random Forest y XGBoost pueden sufrir fácilmente de **sobreajuste (overfitting)** si no se controlan estrictamente.

- **ElasticNet** suele comportarse de manera sobresaliente con muestras de este tamaño porque maneja de forma natural la multicolinealidad entre los 15

indicadores de pobreza y previene el sobreajuste mediante penalizaciones L1 (Lasso) y L2 (Ridge).

- En Random Forest y XGBoost, mantén la profundidad de los árboles baja (max_depth entre 2 y 4) y usa pocos estimadores o regularización alta (gamma, reg_alpha, reg_lambda).

---

3. ¿Qué variables debes usar en el modelo?

Para responder fielmente al Objetivo 3 (*"a partir del Índice de Pobreza Multidimensional, de sus dimensiones y de sus indicadores"*):

A. Variable Objetivo (

Y

):

- **Principal:** prom_punt_global (Puntaje global promedio del departamento).
- *(Opcional como análisis complementario):* Podrías entrenar modelos para prom_punt_matematicas y prom_punt_lectura_critica, pero el indicador central de las pruebas es el puntaje global.

B. Variables Predictoras / Features (

X

):

Tienes los **15 indicadores de privación** del IPM:

1. Analfabetismo
2. Bajo logro educativo
3. Barreras a servicios para cuidado de la primera infancia
4. Barreras de acceso a servicios de salud
5. Desempleo de larga duracion
6. Hacinamiento critico
7. Inadecuada eliminacion de excretas
8. Inasistencia escolar
9. Material inadecuado de paredes exteriores
10. Material inadecuado de pisos
11. Rezago escolar

12. Sin acceso a fuente de agua mejorada
13. Sin aseguramiento en salud
14. Trabajo infantil
15. Trabajo informal

Nota sobre la variable ipm:
Como el ipm agregado es una combinación lineal ponderada de estas 15 privaciones, **no es recomendable incluir al mismo tiempo el ipm general y los 15 indicadores** si no usas regularización, por alta colinealidad. Puedes probar dos especificaciones del modelo:

- **Especificación A:** Solo ipm (modelo univariado base / baseline).
- **Especificación B:** Las 15 privaciones (modelo desagregado que ElasticNet/RF/XGBoost pueden aprovechar para medir qué privaciones impactan más el puntaje).

---

4. ¿Necesitas incluir más variables en el dataset agregado?

No necesitas añadir más variables externas obligatoriamente, pero debes tener en cuenta lo siguiente:

1. **Sobre prom_estu_inse_individual:** Ya lo tienes en el archivo unido, pero **no lo incluyas como predictora principal** si tu objetivo es evaluar el impacto del IPM del DANE. El INSE proviene del mismo ICFES y está altamente correlacionado de origen con la prueba Saber 11; incluirlo "opacaría" el peso de las privaciones del IPM.
2. **Variable temporal (anio):** Sí debes tener en cuenta el tiempo. Como observaste en tu resumen, *"el desempeño siguió una trayectoria común a todo el país (caída hasta 2021 y recuperación)"*. Puedes incluir el año como variable numérica o variables *dummy* por año para controlar choques macro (tendencia nacional).
3. **Controles estructurales (Opcional):** Si quisieras enriquecer la predicción desde el Saber 11, podrías agregar promedios departamentales de:
    - Porcentaje de colegios rurales (COLE_AREA_UBICACION).
    - Porcentaje de colegios oficiales/públicos (COLE_NATURALEZA).
    - *Sin embargo, si tu texto de tesis dice textualmente "a partir del IPM, de sus dimensiones y de sus indicadores", ceñirte a los 15 indicadores es lo metodológicamente más fiel al planteamiento aprobado.*

---

5. Cómo conectar con el Objetivo 4 (Estrategia de validación y simulación)

Para que el Objetivo 3 y el Objetivo 4 queden impecables:

1. **División de datos (Train / Test Split):**
    - **No uses train_test_split aleatorio.** Como son datos de series de tiempo/panel, usar partición aleatoria genera fuga de información temporal (*data leakage*).
    - Usa una **partición temporal**:
        - **Entrenamiento (Train):** Años 2018, 2019, 2021, 2022, 2023 (165 observaciones).
        - **Prueba (Test):** Año 2024 (33 observaciones).
    - De esta forma cumples con la primera parte del Objetivo 4: *"Validar la capacidad predictiva del modelo... sobre años no empleados en su entrenamiento"*.
2. **Métricas de evaluación:**
    - Evalúa los tres modelos (ElasticNet, Random Forest y XGBoost) con

R2*R*2

, **RMSE** (Raíz del Error Cuadrático Medio) y **MAE** (Error Absoluto Medio) sobre el conjunto de test (año 2024).

3. **Escenarios del Objetivo 4 (Simulación *What-If*):**
    - Una vez elijas el mejor modelo (supongamos ElasticNet o RF), tomas los datos del último año (2024) y simulas escenarios:
        - *Escenario 1:* Reducción del 10% en el Bajo logro educativo o Analfabetismo.
        - *Escenario 2:* Meta de reducción de pobreza nacional al 15%.
    - Pasas esas nuevas matrices modificadas por tu modelo entrenado y calculas cuánto subiría el puntaje Saber 11 proyectado por departamento.

Respuesta de la ia sobre los modelos implementados

Model 12:30 p.m.

El diseño metodológico que implementaste es **impecable**:

1. **Partición temporal correcta:** Entrenaste con 2018–2022 y evaluaste en 2023–2024 (*out-of-sample temporal*).
2. **Validación cruzada robusta:** El uso de StratifiedGroupKFold agrupando por departamento evita la fuga de información entre observaciones del mismo territorio.
3. **Manejo de dimensionalidad y desbalance:** Regularizaciones L1/L2 y control de pesos de clase bien calibrados.

Al convertir el problema en una clasificación (probabilidad de superar el umbral de 250 puntos), la **Regresión Logística con ElasticNet** resulta conceptual y técnicamente aplicable.

A continuación tienes la comparativa técnica, la interpretación de resultados y la redacción sugerida para tu tesis.

---

1. Tabla Comparativa de Resultados (Test 2023–2024)

Modelo	ROC-AUC (CV)	ROC-AUC (Test)	Brier Score	Accuracy	F1-Score (Clase 1)	Diagnóstico
ElasticNet (Logística)	0.9157	**0.9459**	0.1215	**0.91**	**0.90**	**Ganador en capacidad predictiva y generalización**
Random Forest	0.9493	0.9292	**0.1066**	0.86	0.84	Mejor calibración probabilística (menor Brier)
XGBoost Regularizado	**0.9544**	0.9189	0.1283	0.85	0.82	Leve sobreajuste respecto a CV, pero competitivo

---

2. Hallazgos Analíticos Clave

A. El modelo ganador: Regresión Logística con ElasticNet

- **Mayor poder discriminante:** Obtuvo el **ROC-AUC más alto en test (0.9459)** y un **F1-score de 0.90** en la clase de interés (departamentos con desempeño

≥250≥250

).

- **Capacidad de selección de variables (Parsimonia):** Gracias a la penalización L1 (l1_ratio = 0.8), el modelo anuló 6 variables redundantes/colineales, quedándose con las 10 privaciones más explicativas.

B. Consistencia transversal entre los 3 modelos (Consenso de Importancia)

Existe un acuerdo notable entre los tres algoritmos sobre qué privaciones determinan el rezago educativo:

1. **Inadecuada eliminación de excretas:** Es, por amplio margen, el factor más determinante (coeficiente de −0.807−0.807

en ElasticNet, 50% de importancia en RF y 27.5% en XGBoost). Más que el saneamiento en sí, actúa como un trazador de **pobreza rural y periurbana extrema / falta de infraestructura territorial**.

2. **Trabajo informal:** Segundo predictor más negativo en ElasticNet (

−0.501−0.501

). Captura la precariedad de los ingresos del hogar y la vulnerabilidad económica familiar.

3. **Analfabetismo y Falta de acceso a fuente de agua mejorada:** Aparecen consistentemente en el *Top 4* de los tres modelos.

4. **El ipm global:** Mantiene signo negativo consistente y alta importancia relativa, validando la hipótesis central.

---

3. Redacción sugerida para el documento de grado (Objetivo 3)

Puedes adaptar estos dos apartados directamente en tu capítulo de resultados:

Apartado A: Comparación de modelos y selección del modelo final

"Para dar cumplimiento al tercer objetivo específico, se evaluaron tres arquitecturas de aprendizaje automático supervisado: Regresión Logística regularizada mediante ElasticNet, Bosques Aleatorios (Random Forest) y XGBoost con regularización estricta. La evaluación sobre la muestra de prueba fuera de tiempo (años 2023 y 2024,

N=66N=66

) evidenció que el modelo con mejor desempeño predictivo general fue la ***Regresión Logística con ElasticNet****, alcanzando un área bajo la curva ROC (ROC-AUC) de* ***0.9459****, una exactitud global (Accuracy) de* ***91%*** *y un F1-Score de* ***0.90*** *para la categoría de alto desempeño (puntaje*

≥250≥250

). Por su parte, Random Forest y XGBoost presentaron métricas ROC-AUC de 0.9292 y 0.9189 respectivamente. Aunque Random Forest obtuvo una ligera ventaja en términos de calibración del error cuadrático (Brier Score de 0.1066 frente a 0.1215 de ElasticNet), se seleccionó el modelo ***ElasticNet*** *como la especificación principal debido a su superioridad en discriminación fuera de muestra y a su interpretabilidad analítica directa a través de coeficientes penalizados."*

Apartado B: Discusión sustantiva de los predictores

"El análisis de coeficientes e importancias relativas arrojó una coincidencia estructural entre las tres técnicas. La privación por ***Inadecuada eliminación de excretas*** *emergió como el predictor de mayor peso negativo sobre el logro educativo (coeficiente de*

−0.807−0.807

en ElasticNet; 50.04% de importancia Gini en Random Forest). Este resultado sugiere que las condiciones más críticas de saneamiento básico operan como variables proxy del aislamiento geográfico y la desatención estatal en infraestructura social básica. En segundo orden, el ***Trabajo informal*** *(*

−0.501−0.501

) y el ***Analfabetismo*** *(*

−0.068−0.068

) se consolidaron como las dimensiones socioeconómicas familiares con mayor capacidad de arrastre negativo sobre la probabilidad de que un departamento supere el umbral de 250 puntos en las pruebas Saber 11."

---

4. Cómo conectar esto con el Objetivo 4 (Simulaciones)

Para el Objetivo 4 (*"estimar el desempeño académico departamental esperado bajo escenarios de reducción del IPM"*), la fórmula logística de tu mejor modelo te permite calcular directamente probabilidades simuladas:

1. **Línea Base (2024):** Tienes el vector de privaciones de cada departamento en 2024 y calculas su probabilidad actual:

P(Puntaje≥250)=11+e−(β0+∑βiXi,2024)*P*(Puntaje≥250)=1+*e*−(*β*0+∑*βiXi*,2024)1

2. **Escenario Simulado (ej. Cierre de brechas en saneamiento y empleo):**
    - Reduces artificialmente un 20% la privación de Inadecuada eliminacion de excretas y Trabajo informal en departamentos periféricos (Chocó, La Guajira, Vaupés, etc.).
3. **Resultado a reportar:** Muestras cómo se incrementa la probabilidad de éxito de cada departamento ante políticas públicas dirigidas a esos indicadores específicos.

Tus gráficos **no son simples en absoluto; metodológicamente son muy potentes**. Sin embargo, entiendo tu preocupación: a veces los gráficos por sí solos parecen un ejercicio estático si no se explota toda la analítica que hay detrás.

Aquí tienes un diagnóstico de **por qué tus resultados son valiosos** y **4 recomendaciones concretas de analítica avanzada** para llevar este cierre a un nivel sobresaliente de posgrado.

---

1. El gran hallazgo que debes explotar: La "Paradoja de la Intervención Sectorial"

En tu primer gráfico tienes un hallazgo de política pública brutal que no puedes dejar pasar de largo:

- **El escenario educativo puro (-50% en Analfabetismo, Rezago e Inasistencia)**: Los triángulos naranjas apenas se mueven de la línea base roja. La mejora en probabilidad es prácticamente marginal (+1% a +3%).
- **El escenario estructural (-30% excretas, informalidad, agua) o choque integral**: Provoca saltos de más de 30 y 40 puntos porcentuales.

Interpretación para tu tesis:

*Este resultado contradice la intuición convencional de que los resultados de calidad educativa se mejoran principalmente desde el sector educación. Demuestra empíricamente el fenómeno de la **"trampa de pobreza estructural"**: una secretaría de educación departamental puede erradicar el rezago escolar, pero si el estudiante vive en un hogar con piso de tierra, sin alcantarillado y con padres en informalidad extrema, las*

restricciones biológicas y de entorno imponen un techo de cristal al rendimiento académico.

---

2. Cuatro formas de elevar y profundizar la parte final

Para que la sección no se quede solo en dos gráficos de barras/mancuernas (*dumbbell plots*), incorpora los siguientes análisis:

Recomendación 1: Matriz de "Departamentos en Umbral de Quiebre" (*Tipping Points*)

No trates a todos los departamentos por igual. Crea una tabla o segmentación analítica que divida a Colombia en tres grupos frente a la política de reducción estructural (-30%):

1. **Los Consolidados (Inmunes al umbral):** Departamentos que ya superaban el 50% de probabilidad y la política solo los acerca al 90% (Bogotá, Caldas, Cundinamarca, Antioquia, Santander).
2. **Los Territorios de "Vuelco" o *Tipping Point* (El mayor retorno de inversión social):** Departamentos que **estaban por debajo del 50% y la política los cruzó al lado favorable** (Cesar, Caquetá, Arauca, Putumayo, Guaviare, Nariño, Magdalena, Bolívar, Sucre, Córdoba).
    - *Aquí es donde el Estado debe priorizar recursos porque el retorno marginal en desempeño educativo es el máximo.*
3. **Los Atrapados en Trampa Severa:** Departamentos que aun con una reducción del 30% en privaciones estructurales **siguen por debajo del umbral del 50%** (La Guajira: 42%, Guainía: 29%, Chocó: 29%, Vaupés: 28%, Vichada: 10%).
    - *Conclusión:* La periferia extrema no responde a mejoras incrementales del 30%; requiere intervenciones no lineales (el plan de choque integral de tu gráfico 1).

Recomendación 2: Medición de Convergencia / Reducción de la Desigualdad Territorial

En el resumen de tu tesis mencionas explícitamente: *"la brecha relativa se amplió y el ordenamiento de los departamentos se mantuvo casi inalterado"*.

Aprovecha tu simulación para responder: **¿La política pública reduce la inequidad entre departamentos o solo sube a todos de nivel?**

- Calcula una métrica de dispersión entre las probabilidades departamentales:
    - **Coeficiente de Gini** de las probabilidades de éxito.
    - **Rango intercuartílico** o **Desviación Estándar** entre departamentos.

- Compara:

- Si la desviación estándar entre departamentos disminuye, puedes concluir formalmente en el Objetivo 4: *"La intervención focalizada en servicios básicos e informalidad no solo mejora el rendimiento medio, sino que opera como un mecanismo de convergencia territorial, reduciendo la brecha entre el centro y la periferia en un X%"*.

Recomendación 3: Curva de "Dosis-Respuesta" para la Periferia Crítica

En lugar de fijar arbitrariamente un -30%, toma los 5 departamentos más rezagados (Chocó, La Guajira, Vaupés, Guainía, Vichada) y genera un gráfico de líneas tipo **Dosis-Respuesta**:

- **Eje X:** Porcentaje de reducción de privaciones estructurales (desde 0% hasta 80%, en pasos de 5%).
- **Eje Y:** Probabilidad estimada de desempeño satisfactorio.
- **Línea horizontal:** Umbral del 50%.

¿Qué aporta esto? Te permite responder la pregunta exacta de un tomador de decisiones:

«¿Qué porcentaje exacto de alcantarillado y formalización de empleo necesita Chocó o La Guajira para tener al menos un 50% de probabilidad de tener un desempeño académico promedio nacional?»

Recomendación 4: Descomposición Explicativa con SHAP (Conectando con Random Forest / XGBoost)

Como entrenaste tres modelos (ElasticNet, RF y XGBoost), puedes enriquecer la discusión analítica usando **SHAP (SHapley Additive exPlanations)** sobre dos casos de estudio contrastantes:

- **Caso 1: Bogotá D.C. o Santander** (Alta probabilidad).
- **Caso 2: Chocó o La Guajira** (Baja probabilidad).

Un gráfico tipo **SHAP Waterfall (cascada)** para cada uno de estos dos departamentos desglosará visualmente cómo cada privación específica resta o suma puntos porcentuales a la predicción final. Esto demuestra el dominio técnico de técnicas modernas de interpretabilidad en analítica (XAI - *Explainable AI*).

---

3. Estructura sugerida para enriquecer el Capítulo del Objetivo 4

Para darle la solidez de una tesis de especialización/maestría, organiza esta sección final así:

1. **Definición y Justificación Teórica de los Escenarios Contrafactuales:**
    - Por qué se eligió el escenario sectorial educativo vs. el estructural (respaldado por la literatura del Banco de la República / DNP).
2. **Evaluación Comparativa de Políticas (Tus dos gráficos actuales):**
    - Interpretación del efecto nulo de la política sectorial frente a la estructural.
3. **Análisis de Tipología Territorial y Retornos Marginales:**
    - La tabla de clasificación (Consolidados, Tipping Points, Trampas de pobreza).
4. **Análisis de Convergencia Interdepartamental:**
    - Métricas de reducción de brechas territoriales (Gini / Varianza antes vs. después).
5. **Recomendaciones de Política Pública Basadas en Datos:**
    - Cerrar con 3 lineamientos aplicados para el Ministerio de Educación, el DNP y los gobiernos departamentales.