estoy realizando el trabajo final de mi especialicacion en analitica de datos, en el cual tengo que diseñart un modelo y probarlo, pero tengo muchas dudas, primero debo entrenar el modelo con todos los datos resultantes despues de la limpipeza, o demo promediar por departamento, que variablas devo de usuar para el modelo, para que me ayudeas a resolver todas esta dudas te paso la siguiente informacion
primero parte de la tesis, para que tengas un poco mas de contexto, lo que debo realiazar es el objetivo 3, tambien te voy a pasar la descripcion de las variables de los tres dataset ictes imp y ya unido pero promediado por departamento, y entes ultimo me gustaria que me digasa si necesitara incluir mas variables en caso de que se la mejor obcion promediar por departamento, ademas te paso los nombres de los tres modelos que estado probando hasta ahora
resumen
El presente proyecto de analítica investiga la relación entre la pobreza multidimensional y el desempeño académico en la educación media colombiana durante el periodo 2018-2024. El problema abordado se centra en las diferencias regionales y socioeconómicas que, lejos de disminuir, tienden a reproducirse a través del sistema educativo y que afectan principalmente a los departamentos periféricos con mayores rezagos estructurales. Siendo así, el objetivo general es analizar la relación entre el Índice de Pobreza Multidimensional (IPM) y los resultados de las pruebas Saber 11 a nivel departamental, mediante la integración de la información oficial del DANE y del ICFES.
La metodología corresponde a un enfoque cuantitativo, de tipo correlacional con alcance predictivo, aplicado a un panel de los 32 departamentos y Bogotá D.C. en los años 2018, 2019 y 2021 a 2024, con exclusión de 2020 por las condiciones atípicas de aplicación de la prueba, para un total de 198 observaciones departamento-año construidas a partir de 2.984.199 estudiantes de grado 11. El documento presenta el desarrollo completo del primer objetivo específico, es decir, la descripción del IPM, de sus cinco dimensiones y quince indicadores y del desempeño académico mediante estadística descriptiva y análisis exploratorio, y deja planteados los modelos de datos de panel con efectos fijos y el modelo predictivo de regresión regularizada de los objetivos restantes.
Entre los principales hallazgos se encuentra que la incidencia media departamental del IPM descendió de 27,9 % a 17,7 % entre 2018 y 2024, sin que ello implicara una convergencia entre territorios, ya que la brecha relativa se amplió y el ordenamiento de los departamentos se mantuvo casi inalterado; que el desempeño en Saber 11 siguió una trayectoria común a todo el país, con un descenso hasta 2021 y una recuperación posterior, conservando una distancia cercana a 30 puntos entre los departamentos de menor y mayor pobreza; y que la asociación entre ambas variables es negativa y consistente entre departamentos ($r = -0,72$), pero prácticamente nula en los cambios de cada departamento a lo largo del tiempo ($r = -0,08$), lo cual constituye un insumo decisivo para la especificación de los modelos de los objetivos siguientes.
Palabras clave: desempeño académico, pobreza multidimensional, Índice de Pobreza Multidimensional, pruebas Saber 11, educación media colombiana.
Objetivo general
Analizar la relación entre el Índice de Pobreza Multidimensional (IPM) y el desempeño académico en la educación media de los departamentos de Colombia durante el periodo

2018-2024, mediante la integración de información oficial del DANE y del ICFES.
Objetivos específicos
Describir el comportamiento del Índice de Pobreza Multidimensional, de sus cinco dimensiones y quince indicadores, y del desempeño académico en las pruebas Saber 11, a nivel departamental en Colombia durante el periodo 2018-2024, mediante estadística descriptiva y análisis exploratorio de datos.
Estimar la asociación entre el Índice de Pobreza Multidimensional y el desempeño académico departamental en Colombia durante el periodo 2018-2024, mediante modelos de datos de panel con efectos fijos de departamento y de año.
Diseñar un modelo predictivo de aprendizaje automático a nivel departamental que estime el desempeño académico en las pruebas Saber 11 a partir del Índice de Pobreza Multidimensional, de sus dimensiones y de sus indicadores, durante el periodo 2018-2024.
Validar la capacidad predictiva del modelo de aprendizaje automático sobre años no empleados en su entrenamiento y estimar el desempeño académico departamental esperado bajo escenarios de reducción del Índice de Pobreza Multidimensional.
metodologia
El presente apartado constituye el plan de trabajo que orienta el desarrollo del proyecto e incluye las herramientas, los insumos y la forma de trabajo bajo los lineamientos metodológicos más apropiados para el cumplimiento de los objetivos planteados. A la fecha se han completado la extracción e integración de las fuentes, la validación de la calidad de los datos y el análisis descriptivo y exploratorio que responde al primer objetivo específico, por lo que estas fases se describen en tiempo pasado con las cifras efectivamente obtenidas; las fases de modelación, validación y predicción se encuentran planeadas y se describen en tiempo futuro.
Enfoque de investigación
El enfoque de investigación más adecuado es el cuantitativo, en tanto se orienta a la medición objetiva de variables y al análisis de relaciones entre fenómenos observables. De acuerdo con Huamán Rojas et al. (2022), el enfoque cuantitativo se sustenta en el paradigma positivista, caracterizado por el uso de datos numéricos, la formulación de hipótesis y la aplicación de técnicas estadísticas, matemáticas o econométricas para explicar y predecir comportamientos; es importante resaltar que por medio de este enfoque se busca generalizar resultados mediante diseños estructurados y análisis inferenciales.

descripcion de variables

Informe de Variables por Archivo CSV

Carpeta analizada: aarchivos finales

Archivo: ipm_departamental_limpio_sin_2020.csv

- **Filas aproximadas (sin encabezado):** 198
- **Encoding detectado/lectura:** utf-8-sig
- **Separador:** ;

- **N. columnas:** 19

Detalle / descripcion inferida

- codigo_departamento: Codigo DIVIPOLA del departamento.
- departamento: Nombre del departamento.
- anio: Anio del registro (en Saber viene como PERIODO ej. 20182 -> anio 2018).
- ipm: Indice de Pobreza Multidimensional departamental.
- Analfabetismo: Privacion: analfabetismo.
- Bajo logro educativo: Privacion: bajo logro educativo.
- Barreras a servicios para cuidado de la primera infancia: Privacion: barreras a servicios para cuidado primera infancia.
- Barreras de acceso a servicios de salud: Privacion: barreras acceso servicios salud.
- Desempleo de larga duracion: Privacion: desempleo larga duracion.
- Hacinamiento critico: Privacion: hacinamiento critico.
- Inadecuada eliminacion de excretas: Privacion: inadecuada eliminacion excretas.
- Inasistencia escolar: Privacion: inasistencia escolar.
- Material inadecuado de paredes exteriores: Privacion: material inadecuado paredes exteriores.
- Material inadecuado de pisos: Privacion: material inadecuado pisos.
- Rezago escolar: Privacion: rezago escolar.
- Sin acceso a fuente de agua mejorada: Privacion: sin acceso fuente agua mejorada.
- Sin aseguramiento en salud: Privacion: sin aseguramiento en salud.
- Trabajo infantil: Privacion: trabajo infantil.
- Trabajo informal: Privacion: trabajo informal.

Archivo: Saber_11_Listo_2018_2024.csv

- **Filas aproximadas (sin encabezado):** 3401100
- **Encoding detectado/lectura:** utf-8
- **Separador:** ,
- **N. columnas:** 79

Detalle / descripcion inferida

- PERIODO: Anio del registro (en Saber viene como PERIODO ej. 20182 -> anio 2018).

- ESTU_ESTUDIANTE: Variable original Saber/panel. Valores unicos en muestra: 1.
- ESTU_TIPODOCUMENTO: Variable original Saber/panel. Valores unicos en muestra: 6.
- COLE_AREA_UBICACION: Variable original Saber/panel. Valores unicos en muestra: 2.
- COLE_BILINGUE: Variable original Saber/panel. Valores unicos en muestra: 2.
- COLE_CARACTER: Variable original Saber/panel. Valores unicos en muestra: 4.
- COLE_COD_DEPTO_UBICACION: Codigo DIVIPOLA del departamento.
- COLE_COD_MCPIO_UBICACION: Variable original Saber/panel. Valores unicos en muestra: 85.
- COLE_DEPTO_UBICACION: Variable original Saber/panel. Valores unicos en muestra: 27.
- COLE_GENERO: Variable original Saber/panel. Valores unicos en muestra: 3.
- COLE_JORNADA: Variable original Saber/panel. Valores unicos en muestra: 6.
- COLE_MCPIO_UBICACION: Variable original Saber/panel. Valores unicos en muestra: 85.
- COLE_NATURALEZA: Variable original Saber/panel. Valores unicos en muestra: 2.
- COLE_NOMBRE_ESTABLECIMIENTO: Variable original Saber/panel. Valores unicos en muestra: 429.
- COLE_NOMBRE_SEDE: Variable original Saber/panel. Valores unicos en muestra: 433.
- COLE_SEDE_PRINCIPAL: Variable original Saber/panel. Valores unicos en muestra: 2.
- DESEMP_C_NATURALES: Saber 11: puntaje ciencias naturales (0-100).
- DESEMP_INGLES: Saber 11: puntaje ingles (0-100).
- DESEMP_LECTURA_CRITICA: Saber 11: puntaje lectura critica (0-100).
- DESEMP_MATEMATICAS: Saber 11: puntaje matematicas (0-100).
- DESEMP_SOCIALES_CIUDADANAS: Saber 11: puntaje sociales y ciudadanas (0-100).
- ESTU_AGREGADO: Variable original Saber/panel. Valores unicos en muestra: 2.
- ESTU_COD_DEPTO_PRESENTACION: Variable original Saber/panel. Valores unicos en muestra: 27.
- ESTU_COD_MCPIO_PRESENTACION: Variable original Saber/panel. Valores unicos en muestra: 46.
- ESTU_COD_RESIDE_DEPTO: Variable original Saber/panel. Valores unicos en muestra: 27.

- ESTU_COD_RESIDE_MCPIO: Variable original Saber/panel. Valores unicos en muestra: 92.
- ESTU_DEDICACIONINTERNET: Variable original Saber/panel. Valores unicos en muestra: 5.
- ESTU_DEDICACIONLECTURADIARIA: Saber 11: puntaje lectura critica (0-100).
- ESTU_DEPTO_PRESENTACION: Variable original Saber/panel. Valores unicos en muestra: 27.
- ESTU_DEPTO_RESIDE: Variable original Saber/panel. Valores unicos en muestra: 27.
- ESTU_DISCAPACIDAD: Variable original Saber/panel. Valores unicos en muestra: 2.
- ESTU_FECHANACIMIENTO: Variable original Saber/panel. Valores unicos en muestra: 739.
- ESTU_GENERO: Variable original Saber/panel. Valores unicos en muestra: 2.
- ESTU_GRADO: Variable original Saber/panel. Valores unicos en muestra: 2.
- ESTU_HORASSEMANATRABAJA: Variable original Saber/panel. Valores unicos en muestra: 5.
- ESTU_INSE_INDIVIDUAL: Indice socioeconomico individual (INSE).
- ESTU_MCPIO_PRESENTACION: Variable original Saber/panel. Valores unicos en muestra: 46.
- ESTU_MCPIO_RESIDE: Variable original Saber/panel. Valores unicos en muestra: 92.
- ESTU_NACIONALIDAD: Variable original Saber/panel. Valores unicos en muestra: 6.
- ESTU_NSE_ESTABLECIMIENTO: Variable original Saber/panel. Valores unicos en muestra: 4.
- ESTU_NSE_INDIVIDUAL: Variable original Saber/panel. Valores unicos en muestra: 4.
- ESTU_PAIS_RESIDE: Variable original Saber/panel. Valores unicos en muestra: 6.
- ESTU_PRIVADO_LIBERTAD: Variable original Saber/panel. Valores unicos en muestra: 1.
- ESTU_REPITE: Variable original Saber/panel. Valores unicos en muestra: 72.
- ESTU_TIPOREMUNERACION: Variable original Saber/panel. Valores unicos en muestra: 4.
- FAMI_COMECARNEPESCADOHUEVO: Variable original Saber/panel. Valores unicos en muestra: 4.
- FAMI_COMECEREALFRUTOSLEGUMBRE: Variable original Saber/panel. Valores unicos en muestra: 4.

- FAMI_COMELECHEDERIVADOS: Variable original Saber/panel. Valores unicos en muestra: 4.
- FAMI_CUARTOSHOGAR: Variable original Saber/panel. Valores unicos en muestra: 6.
- FAMI_EDUCACIONMADRE: Variable original Saber/panel. Valores unicos en muestra: 12.
- FAMI_EDUCACIONPADRE: Variable original Saber/panel. Valores unicos en muestra: 12.
- FAMI_ESTRATOVIVIENDA: Variable original Saber/panel. Valores unicos en muestra: 7.
- FAMI_NUMLIBROS: Variable original Saber/panel. Valores unicos en muestra: 4.
- FAMI_PERSONASHOGAR: Variable original Saber/panel. Valores unicos en muestra: 5.
- FAMI_SITUACIONECONOMICA: Variable original Saber/panel. Valores unicos en muestra: 3.
- FAMI_TIENEAUTOMOVIL: Variable original Saber/panel. Valores unicos en muestra: 2.
- FAMI_TIENECOMPUTADOR: Variable original Saber/panel. Valores unicos en muestra: 2.
- FAMI_TIENECONSOLAVIDEOJUEGOS: Variable original Saber/panel. Valores unicos en muestra: 2.
- FAMI_TIENEHORNOMICROOGAS: Variable original Saber/panel. Valores unicos en muestra: 2.
- FAMI_TIENEINTERNET: Variable original Saber/panel. Valores unicos en muestra: 2.
- FAMI_TIENELAVADORA: Variable original Saber/panel. Valores unicos en muestra: 2.
- FAMI_TIENEMOTOCICLETA: Variable original Saber/panel. Valores unicos en muestra: 2.
- FAMI_TIENESERVICIOTV: Variable original Saber/panel. Valores unicos en muestra: 2.
- FAMI_TRABAJOLABORMADRE: Variable original Saber/panel. Valores unicos en muestra: 13.
- FAMI_TRABAJOLABORPADRE: Variable original Saber/panel. Valores unicos en muestra: 13.
- PERCENTIL_C_NATURALES: Saber 11: puntaje ciencias naturales (0-100).
- PERCENTIL_GLOBAL: Percentil global del estudiante.
- PERCENTIL_INGLES: Saber 11: puntaje ingles (0-100).
- PERCENTIL_LECTURA_CRITICA: Saber 11: puntaje lectura critica (0-100).

- PERCENTIL_MATEMATICAS: Saber 11: puntaje matematicas (0-100).
- PERCENTIL_SOCIALES_CIUDADANAS: Saber 11: puntaje sociales y ciudadanas (0-100).
- PUNT_C_NATURALES: Saber 11: puntaje ciencias naturales (0-100).
- PUNT_GLOBAL: Saber 11: puntaje global (0-500).
- PUNT_INGLES: Saber 11: puntaje ingles (0-100).
- PUNT_LECTURA_CRITICA: Saber 11: puntaje lectura critica (0-100).
- PUNT_MATEMATICAS: Saber 11: puntaje matematicas (0-100).
- PUNT_SOCIALES_CIUDADANAS: Saber 11: puntaje sociales y ciudadanas (0-100).
- DEPTO_ANALISIS: Variable original Saber/panel. Valores unicos en muestra: 27.
- ANIO: Anio del registro (en Saber viene como PERIODO ej. 20182 -> anio 2018).

Archivo: panel_departamento_anio_unido.csv

- **Filas aproximadas (sin encabezado):** 198
- **Encoding detectado/lectura:** utf-8-sig
- **Separador:** ,
- **N. columnas:** 37

Detalle / descripcion inferida

- codigo_departamento: Codigo DIVIPOLA del departamento.
- anio: Anio del registro (en Saber viene como PERIODO ej. 20182 -> anio 2018).
- n_estudiantes_saber: Panel: conteo de registros validos para esa variable.
- prom_punt_global: Saber 11: puntaje global (0-500).
- n_punt_global: Saber 11: puntaje global (0-500).
- prom_punt_matematicas: Saber 11: puntaje matematicas (0-100).
- n_punt_matematicas: Saber 11: puntaje matematicas (0-100).
- prom_punt_lectura_critica: Saber 11: puntaje lectura critica (0-100).
- n_punt_lectura_critica: Saber 11: puntaje lectura critica (0-100).
- prom_punt_c_naturales: Saber 11: puntaje ciencias naturales (0-100).
- n_punt_c_naturales: Saber 11: puntaje ciencias naturales (0-100).
- prom_punt_sociales_ciudadanas: Saber 11: puntaje sociales y ciudadanas (0-100).

- n_punt_sociales_ciudadanas: Saber 11: puntaje sociales y ciudadanas (0-100).
- prom_punt_ingles: Saber 11: puntaje ingles (0-100).
- n_punt_ingles: Saber 11: puntaje ingles (0-100).
- prom_percentil_global: Percentil global del estudiante.
- n_percentil_global: Percentil global del estudiante.
- prom_estu_inse_individual: Indice socioeconomico individual (INSE).
- n_estu_inse_individual: Indice socioeconomico individual (INSE).
- departamento: Nombre del departamento.
- ipm: Indice de Pobreza Multidimensional departamental.
- Analfabetismo: Privacion: analfabetismo.
- Bajo logro educativo: Privacion: bajo logro educativo.
- Barreras a servicios para cuidado de la primera infancia: Privacion: barreras a servicios para cuidado primera infancia.
- Barreras de acceso a servicios de salud: Privacion: barreras acceso servicios salud.
- Desempleo de larga duracion: Privacion: desempleo larga duracion.
- Hacinamiento critico: Privacion: hacinamiento critico.
- Inadecuada eliminacion de excretas: Privacion: inadecuada eliminacion excretas.
- Inasistencia escolar: Privacion: inasistencia escolar.
- Material inadecuado de paredes exteriores: Privacion: material inadecuado paredes exteriores.
- Material inadecuado de pisos: Privacion: material inadecuado pisos.
- Rezago escolar: Privacion: rezago escolar.
- Sin acceso a fuente de agua mejorada: Privacion: sin acceso fuente agua mejorada.
- Sin aseguramiento en salud: Privacion: sin aseguramiento en salud.
- Trabajo infantil: Privacion: trabajo infantil.
- Trabajo informal: Privacion: trabajo informal.
- _merge: Indicador de origen del merge (both/left_only/right_only).

Resumen comparativo

Archivo	Filas aprox	Columnas	Llaves principales
ipm_departamental_limpio_sin_2020.csv	ver arriba	19 (3 llaves + ipm + 15 privaciones)	codigo_departamento, departamento, anio
Saber_11_Listo_2018_2024.csv	ver arriba	segun encabezado completo (incluye PUNT_* , PERIODO, COLE_COD_DEPTO_UBICACION, etc.)	COLE_COD_DEPTO_UBICACION, PERIODO
panel_departamento_anio_unido.csv	ver arriba	codigo_departamento, anio + promedios prom_* + conteos n_* + variables IPM + _merge	codigo_departamento, anio

Nota: Saber_11 es archivo grande; el analisis usa muestra de 1000 filas para tipos y ejemplos. Para diccionario completo del Saber, ampliar muestra.

nombres de modelos
Regresión Logística con Regularización ElasticNet
Randon Forest
xgboost_regularizado

te voy a pasar el código de los modelos y los resultados que me generen cada uno

```
import warnings
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import (
brier_score_loss,
classification_report,
confusion_matrix,
```

```
roc_auc_score,
)
from sklearn.model_selection import GridSearchCV, LeaveOneGroupOut
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import StratifiedGroupKFold
```

Ignorar advertencias de convergencia durante pruebas de hiperparámetros

```
warnings.filterwarnings("ignore")
```

==========

1. CARGA Y PREPARACIÓN DE DATOS

==========

Cargar el dataset final

```
df = pd.read_csv("panel_departamento_anio_unido.csv", encoding="utf-8-sig")
```

Filtro metodológico: Solo cruces exitosos y excluir 2021 por anomalía de muestra

```
df_clean = df[(df["_merge"] == "both")].copy()
```

Definición de la variable objetivo: 1 si supera o iguala 250 puntos, 0 si no

```
UMBRAL = 250
df_clean["target"] = (df_clean["prom_punt_global"] >= UMBRAL).astype(int)
```

Lista exacta de tus 16 predictores (IPM global + 15 dimensiones)

```
predictores = [
"ipm",
"Analfabetismo",
"Bajo logro educativo",
"Barreras a servicios para cuidado de la primera infancia",
"Barreras de acceso a servicios de salud",
"Desempleo de larga duracion",
"Hacinamiento critico",
"Inadecuada eliminacion de excretas",
"Inasistencia escolar",
"Material inadecuado de paredes exteriores",
"Material inadecuado de pisos",
"Rezago escolar",
"Sin acceso a fuente de agua mejorada",
"Sin aseguramiento en salud",
"Trabajo infantil",
```

"Trabajo informal",
]

==========

2. PARTICIÓN TEMPORAL (TRAIN vs TEST)

==========

Cohortes de entrenamiento: 2018, 2019, 2022

train_mask = df_clean["anio"].isin([2018, 2019, 2021, 2022])

Cohortes de evaluación fuera de muestra: 2023, 2024

test_mask = df_clean["anio"].isin([2023, 2024])

X_train = df_clean.loc[train_mask, predictores]
y_train = df_clean.loc[train_mask, "target"]
grupos_train = df_clean.loc[train_mask, "codigo_departamento"]

X_test = df_clean.loc[test_mask, predictores]
y_test = df_clean.loc[test_mask, "target"]

print(
f"Dimensiones de entrenamiento: {X_train.shape[0]} filas (departamentos-año)"
)
print(f"Dimensiones de prueba: {X_test.shape[0]} filas (departamentos-año)")
print(f"Distribución del target en Train:\n{y_train.value_counts(normalize=True)}")

==========

3. PIPELINE CORREGIDO Y MALLA DE HIPERPARÁMETROS

==========

pipeline = Pipeline(
[
("scaler", StandardScaler()),
(
"elasticnet",
LogisticRegression(
penalty="elasticnet",
solver="saga",
class_weight="balanced", # Corrige el desbalance 69% vs 31%
max_iter=10000,
random_state=42,

),
),
]
)

Valores de C más realistas (C altos = penalidad moderada/suave)

param_grid = {
"elasticnet__C": [0.01, 0.05, 0.1, 0.5, 1.0, 5.0, 10.0, 50.0],
"elasticnet__l1_ratio": [
0.05,
0.2,
0.5,
0.8,
], # Balance entre Ridge y Lasso
}

Validación cruzada balanceada por grupos (departamentos)

cv_estrategia = StratifiedGroupKFold(n_splits=5)

grid_search = GridSearchCV(
estimator=pipeline,
param_grid=param_grid,
cv=cv_estrategia,
scoring="roc_auc",
n_jobs=-1,
)

==========

4. ENTRENAMIENTO CORREGIDO

==========

print("\nEntrenando con StratifiedGroupKFold...")

Pasamos y_train como etiquetas para estratificar y grupos_train para no romper departamentos

grid_search.fit(X_train, y_train, groups=grupos_train)

best_model = grid_search.best_estimator_
print(f"Mejores hiperparámetros encontrados: {grid_search.best_params_}")
print(f"Mejor ROC-AUC promedio en CV: {grid_search.best_score_:.4f}")

==========

5. EVALUACIÓN FUERA DE MUESTRA (TEST: 2023 - 2024)

==========

Predecir probabilidades y clases en el conjunto de prueba

```
y_probs_test = best_model.predict_proba(X_test)[:, 1]
y_pred_test = (y_probs_test >= 0.5).astype(int)
```

Métricas solicitadas por los objetivos

```
auc = roc_auc_score(y_test, y_probs_test)
brier = brier_score_loss(y_test, y_probs_test)

print("\n--- RESULTADOS EN EL CONJUNTO DE PRUEBA (2023-2024) ---")
print(f"ROC-AUC fuera de muestra: {auc:.4f}")
print(f"Brier Score (Calibración/Error Cuadrático): {brier:.4f}")
print("\nReporte de Clasificación:")
print(classification_report(y_test, y_pred_test))
```

==========

6. INTERPRETACIÓN DE COEFICIENTES (Para el texto de la tesis)

==========

Extraemos los coeficientes del modelo final entrenado

```
coeficientes = best_model.named_steps["elasticnet"].coef_[0]

df_coef = pd.DataFrame(
{"Variable": predictores, "Coeficiente": coeficientes}
).sort_values(by="Coeficiente", ascending=True)

print("\n--- COEFICIENTES ESTIMADOS (Efecto sobre probabilidad de éxito) ---")
print(df_coef.to_string(index=False))
```

Si un coeficiente es 0, ElasticNet determinó que esa variable no aporta información adicional

```
variables_eliminadas = df_coef[df_coef["Coeficiente"] == 0]["Variable"].tolist()
print(f"\nVariables anuladas por ElasticNet (L1): {len(variables_eliminadas)}")
```

resultado
Dimensiones de entrenamiento: 132 filas (departamentos-año)
Dimensiones de prueba: 66 filas (departamentos-año)
Distribución del target en Train:
target
0 0.689394

1 0.310606
Name: proportion, dtype: float64

Entrenando con StratifiedGroupKFold...
Mejores hiperparámetros encontrados: {'elasticnet__C': 0.1, 'elasticnet__l1_ratio': 0.8}
Mejor ROC-AUC promedio en CV: 0.9157

--- RESULTADOS EN EL CONJUNTO DE PRUEBA (2023-2024) ---
ROC-AUC fuera de muestra: 0.9459
Brier Score (Calibración/Error Cuadrático): 0.1215

Reporte de Clasificación:
precision recall f1-score support

codeCode

0 0.94 0.89 0.92 37

1 0.87 0.93 0.90 29

accuracy 0.91 66

macro avg 0.91 0.91 0.91 66
weighted avg 0.91 0.91 0.91 66

--- COEFICIENTES ESTIMADOS (Efecto sobre probabilidad de éxito) ---
Variable Coeficiente
Inadecuada eliminacion de excretas -0.807109
Trabajo informal -0.501191
Sin acceso a fuente de agua mejorada -0.238432
ipm -0.073195
Analfabetismo -0.068312
Hacinamiento critico -0.061380
Material inadecuado de pisos -0.044276
Rezago escolar -0.018063
Barreras a servicios para cuidado de la primera infancia -0.014390
Inasistencia escolar -0.008126
Bajo logro educativo 0.000000
Desempleo de larga duracion 0.000000
Barreras de acceso a servicios de salud 0.000000
Material inadecuado de paredes exteriores 0.000000
Sin aseguramiento en salud 0.000000
Trabajo infantil 0.000000

Variables anuladas por ElasticNet (L1): 6

segundo modelo
import warnings

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import (
brier_score_loss,
classification_report,
confusion_matrix,
roc_auc_score,
)
from sklearn.model_selection import GridSearchCV, StratifiedGroupKFold

warnings.filterwarnings("ignore")

================================================================================

1. CARGA Y PREPARACIÓN DE DATOS

================================================================================

df = pd.read_csv("panel_departamento_anio_unido.csv", encoding="utf-8-sig")

Filtro de cruces válidos (Saber + IPM)

df_clean = df[df["_merge"] == "both"].copy()

Target binario: 1 si puntaje >= 250, 0 en caso contrario

UMBRAL = 250
df_clean["target"] = (df_clean["prom_punt_global"] >= UMBRAL).astype(int)

Los 16 predictores

predictores = [
"ipm",
"Analfabetismo",
"Bajo logro educativo",
"Barreras a servicios para cuidado de la primera infancia",
"Barreras de acceso a servicios de salud",
"Desempleo de larga duracion",
"Hacinamiento critico",
"Inadecuada eliminacion de excretas",
"Inasistencia escolar",
"Material inadecuado de paredes exteriores",
"Material inadecuado de pisos",
"Rezago escolar",
```

"Sin acceso a fuente de agua mejorada",
"Sin aseguramiento en salud",
"Trabajo infantil",
"Trabajo informal",
]

==========

2. PARTICIÓN TEMPORAL

==========

```
train_mask = df_clean["anio"].isin([2018, 2019, 2021, 2022])
test_mask = df_clean["anio"].isin([2023, 2024])

X_train = df_clean.loc[train_mask, predictores]
y_train = df_clean.loc[train_mask, "target"]
grupos_train = df_clean.loc[train_mask, "codigo_departamento"]

X_test = df_clean.loc[test_mask, predictores]
y_test = df_clean.loc[test_mask, "target"]
```

Nota: Los árboles de decisión NO requieren StandardScaler (son invariantes a escalas monótonas)

==========

3. MALLA DE HIPERPARÁMETROS REGULARIZADOS

==========

```
rf = RandomForestClassifier(random_state=42, class_weight="balanced")
```

Espacio de búsqueda acotado para forzar árboles conservadores y no sobreajustados

```
param_grid = {
"n_estimators": [100, 200],
"max_depth": [2, 3, 4], # Árboles poco profundos
"min_samples_leaf": [3, 5, 8], # Hojas con suficientes observaciones
"min_samples_split": [6, 10, 15], # Dificultad para dividir nodos
"max_features": [
"sqrt",
0.3,
0.5,
], # Fracción de predictores por división
}
```

Misma estrategia de validación cruzada agrupada por departamento

```
cv_estrategia = StratifiedGroupKFold(n_splits=5)

grid_search_rf = GridSearchCV(
estimator=rf,
param_grid=param_grid,
cv=cv_estrategia,
scoring="roc_auc",
n_jobs=-1,
)
```

==========

4. ENTRENAMIENTO

==========

```
print("Entrenando Random Forest con regularización...")
grid_search_rf.fit(X_train, y_train, groups=grupos_train)

best_rf = grid_search_rf.best_estimator_
print(f"Mejores hiperparámetros encontrados: {grid_search_rf.best_params_}")
print(f"Mejor ROC-AUC promedio en CV: {grid_search_rf.best_score_:.4f}")
```

==========

5. EVALUACIÓN FUERA DE MUESTRA (TEST: 2023 - 2024)

==========

```
y_probs_rf = best_rf.predict_proba(X_test)[:, 1]
y_pred_rf = (y_probs_rf >= 0.5).astype(int)

auc_rf = roc_auc_score(y_test, y_probs_rf)
brier_rf = brier_score_loss(y_test, y_probs_rf)

print("\n--- RESULTADOS RANDOM FOREST EN TEST (2023-2024) ---")
print(f"ROC-AUC fuera de muestra: {auc_rf:.4f}")
print(f"Brier Score (Error Cuadrático): {brier_rf:.4f}")
print("\nReporte de Clasificación:")
print(classification_report(y_test, y_pred_rf))
```

==========

6. IMPORTANCIA DE VARIABLES (Feature Importance)

==========
===

Calculamos la importancia relativa de cada dimensión según la reducción de impureza Gini

```
importancias = best_rf.feature_importances_
df_importancias = pd.DataFrame(
{"Variable": predictores, "Importancia": importancias}
).sort_values(by="Importancia", ascending=False)

print("\n--- IMPORTANCIA DE VARIABLES (Gini Importance) ---")
print(df_importancias.to_string(index=False))
```

resultados
Entrenando Random Forest con regularización...
Mejores hiperparámetros encontrados: {'max_depth': 4, 'max_features': 0.5, 'min_samples_leaf': 5, 'min_samples_split': 6, 'n_estimators': 100}
Mejor ROC-AUC promedio en CV: 0.9493

--- RESULTADOS RANDOM FOREST EN TEST (2023-2024) ---
ROC-AUC fuera de muestra: 0.9292
Brier Score (Error Cuadrático): 0.1066

Reporte de Clasificación:
precision recall f1-score support

codeCode

0 0.87 0.89 0.88 37

1 0.86 0.83 0.84 29

accuracy 0.86 66

macro avg 0.86 0.86 0.86 66
weighted avg 0.86 0.86 0.86 66

--- IMPORTANCIA DE VARIABLES (Gini Importance) ---
Variable Importancia
Inadecuada eliminacion de excretas 0.500429
ipm 0.129652
Analfabetismo 0.055793
Material inadecuado de pisos 0.052330
Sin acceso a fuente de agua mejorada 0.051116
Material inadecuado de paredes exteriores 0.047621
Hacinamiento critico 0.035931
Barreras de acceso a servicios de salud 0.025920

Trabajo informal 0.024950
Trabajo infantil 0.022108
Rezago escolar 0.012292
Bajo logro educativo 0.012211
Sin aseguramiento en salud 0.009689
Desempleo de larga duracion 0.008306
Barreras a servicios para cuidado de la primera infancia 0.007254
Inasistencia escolar 0.004398
tercer modelo

```
import warnings
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from sklearn.metrics import (
brier_score_loss,
classification_report,
roc_auc_score,
)
from sklearn.model_selection import GridSearchCV, StratifiedGroupKFold
import xgboost as xgb

warnings.filterwarnings("ignore")

================================================================================

1. CARGA Y PREPARACIÓN DE DATOS

================================================================================

df = pd.read_csv("panel_departamento_anio_unido.csv", encoding="utf-8-sig")
df_clean = df[df["_merge"] == "both"].copy()

UMBRAL = 250
df_clean["target"] = (df_clean["prom_punt_global"] >= UMBRAL).astype(int)

predictores = [
"ipm",
"Analfabetismo",
"Bajo logro educativo",
"Barreras a servicios para cuidado de la primera infancia",
"Barreras de acceso a servicios de salud",
"Desempleo de larga duracion",
"Hacinamiento critico",
"Inadecuada eliminacion de excretas",
"Inasistencia escolar",
"Material inadecuado de paredes exteriores",
```

"Material inadecuado de pisos",
"Rezago escolar",
"Sin acceso a fuente de agua mejorada",
"Sin aseguramiento en salud",
"Trabajo infantil",
"Trabajo informal",
]

==========

2. PARTICIÓN TEMPORAL

==========

train_mask = df_clean["anio"].isin([2018, 2019, 2021, 2022])
test_mask = df_clean["anio"].isin([2023, 2024])

X_train = df_clean.loc[train_mask, predictores]
y_train = df_clean.loc[train_mask, "target"]
grupos_train = df_clean.loc[train_mask, "codigo_departamento"]

X_test = df_clean.loc[test_mask, predictores]
y_test = df_clean.loc[test_mask, "target"]

Peso para compensar el desbalance (negativos / positivos en train ≈ 91 / 41 ≈ 2.2)

ratio_desbalance = (y_train == 0).sum() / (y_train == 1).sum()

==========

3. MALLA DE HIPERPARÁMETROS REGULARIZADOS

==========

xgb_clf = xgb.XGBClassifier(
eval_metric="logloss",
random_state=42,
scale_pos_weight=ratio_desbalance, # Balancea clases
)

param_grid = {
"n_estimators": [50, 100], # Pocos árboles para evitar overfitting
"max_depth": [2, 3], # Árboles muy poco profundos
"learning_rate": [0.01, 0.03, 0.05], # Tasa de aprendizaje prudente
"subsample": [0.7, 0.85], # Submuestreo de filas
"colsample_bytree": [0.5, 0.7], # Submuestreo de variables

```
"reg_alpha": [0.1, 1.0], # Regularización L1 (Lasso)
"reg_lambda": [1.0, 5.0], # Regularización L2 (Ridge)
}
```

Misma estrategia de validación agrupada por departamento

```
cv_estrategia = StratifiedGroupKFold(n_splits=5)

grid_search_xgb = GridSearchCV(
estimator=xgb_clf,
param_grid=param_grid,
cv=cv_estrategia,
scoring="roc_auc",
n_jobs=-1,
)
```

==========

4. ENTRENAMIENTO

==========

```
print("Entrenando XGBoost con regularización estricta...")
grid_search_xgb.fit(X_train, y_train, groups=grupos_train)

best_xgb = grid_search_xgb.best_estimator_
print(f"Mejores hiperparámetros encontrados: {grid_search_xgb.best_params_}")
print(f"Mejor ROC-AUC promedio en CV: {grid_search_xgb.best_score_:.4f}")
```

==========

5. EVALUACIÓN FUERA DE MUESTRA (TEST: 2023 - 2024)

==========

```
y_probs_xgb = best_xgb.predict_proba(X_test)[:, 1]
y_pred_xgb = (y_probs_xgb >= 0.5).astype(int)

auc_xgb = roc_auc_score(y_test, y_probs_xgb)
brier_xgb = brier_score_loss(y_test, y_probs_xgb)

print("\n--- RESULTADOS XGBOOST EN TEST (2023-2024) ---")
print(f"ROC-AUC fuera de muestra: {auc_xgb:.4f}")
print(f"Brier Score (Calibración): {brier_xgb:.4f}")
print("\nReporte de Clasificación:")
print(classification_report(y_test, y_pred_xgb))
```

==========

6. IMPORTANCIA DE VARIABLES (Weight / Gain)

==========

```
importancias = best_xgb.feature_importances_
df_importancias = pd.DataFrame(
{"Variable": predictores, "Importancia (Gain)": importancias}
).sort_values(by="Importancia (Gain)", ascending=False)

print("\n--- IMPORTANCIA DE VARIABLES EN XGBOOST ---")
print(df_importancias.to_string(index=False))
```

resultados
Entrenando XGBoost con regularización estricta...
Mejores hiperparámetros encontrados: {'colsample_bytree': 0.7, 'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 100, 'reg_alpha': 1.0, 'reg_lambda': 1.0, 'subsample': 0.85}
Mejor ROC-AUC promedio en CV: 0.9544

--- RESULTADOS XGBOOST EN TEST (2023-2024) ---
ROC-AUC fuera de muestra: 0.9189
Brier Score (Calibración): 0.1283

Reporte de Clasificación:
precision recall f1-score support

codeCode

0 0.85 0.89 0.87 37

1 0.85 0.79 0.82 29

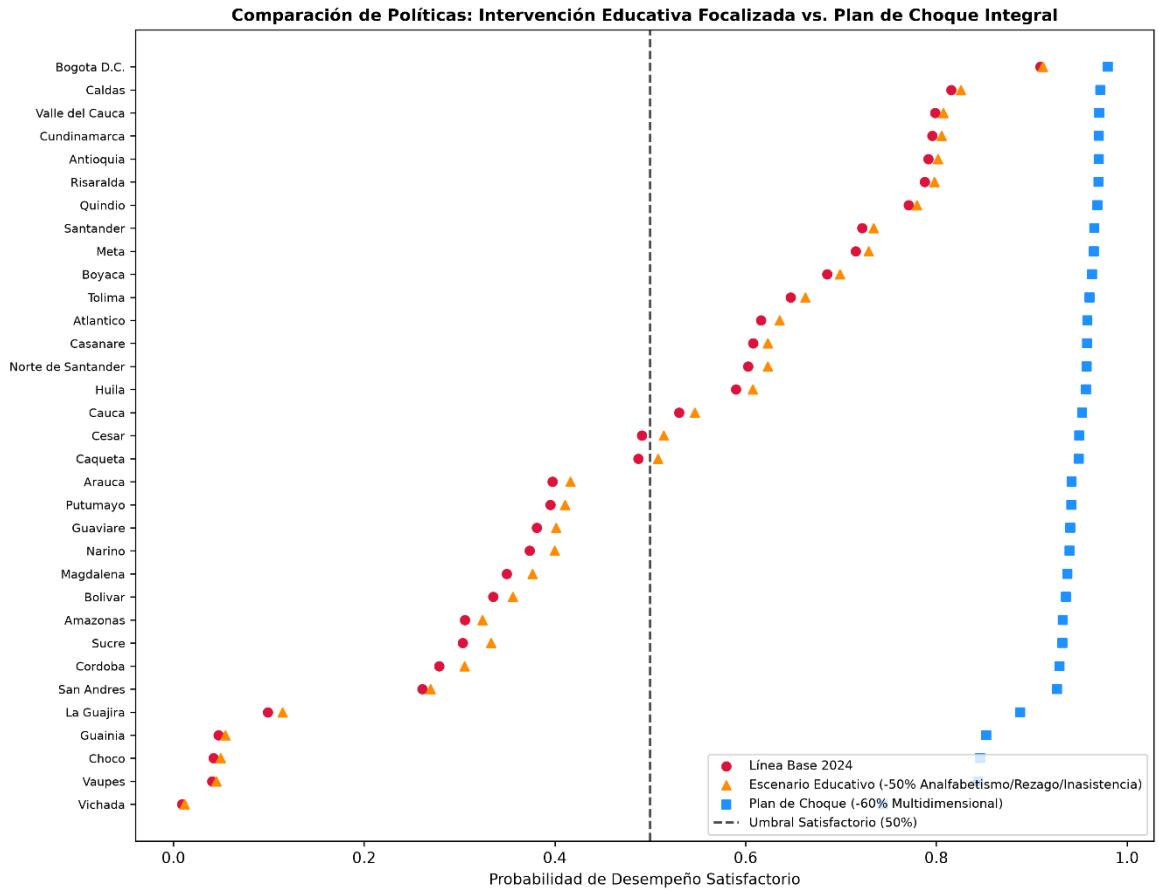
accuracy 0.85 66

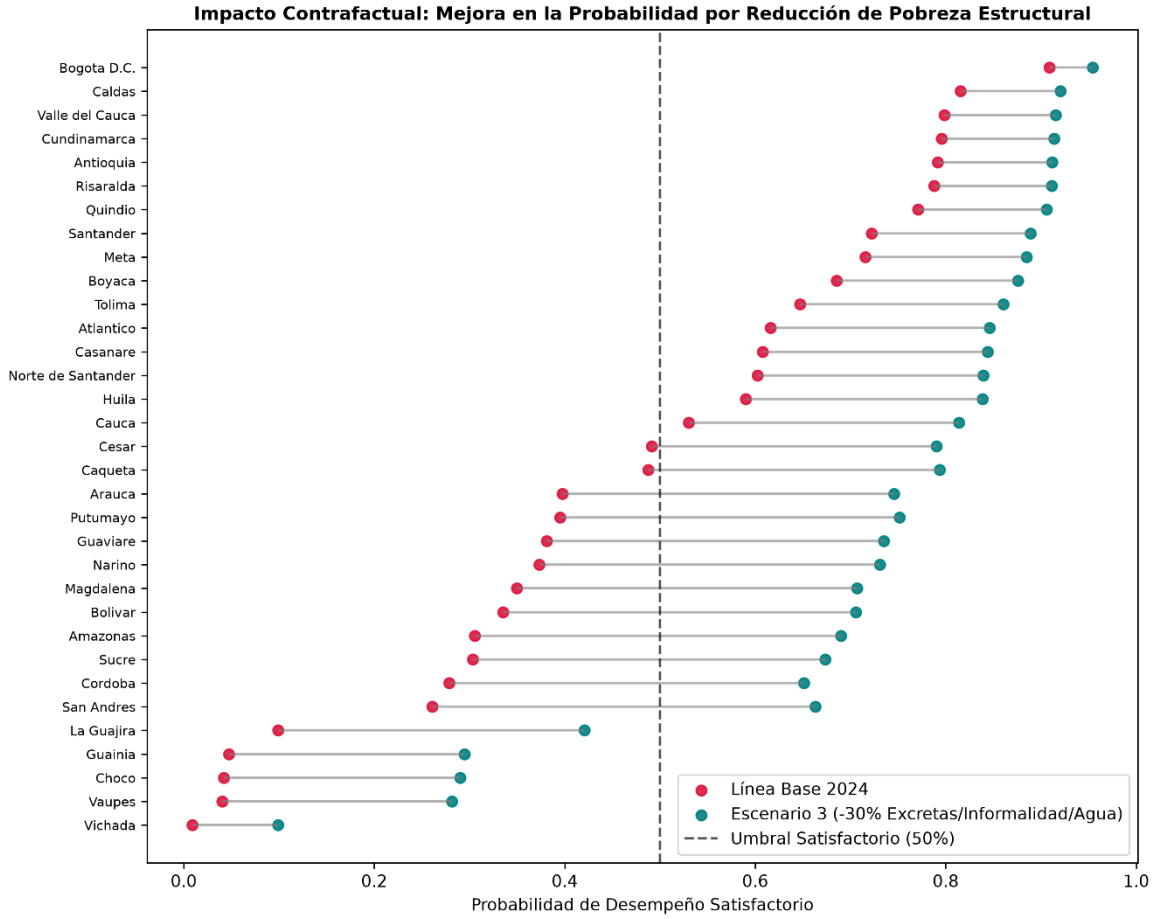
macro avg 0.85 0.84 0.84 66
weighted avg 0.85 0.85 0.85 66

--- IMPORTANCIA DE VARIABLES EN XGBOOST ---
Variable Importancia (Gain)
Inadecuada eliminacion de excretas 0.274869
Analfabetismo 0.172421
ipm 0.136405
Sin acceso a fuente de agua mejorada 0.078745
Material inadecuado de pisos 0.049785
Material inadecuado de paredes exteriores 0.046892
Hacinamiento critico 0.041199

Barreras de acceso a servicios de salud 0.040938
Trabajo informal 0.032280
Trabajo infantil 0.027789
Inasistencia escolar 0.027306
Barreras a servicios para cuidado de la primera infancia 0.027111
Sin aseguramiento en salud 0.026461
Desempleo de larga duracion 0.013928
Bajo logro educativo 0.003870
Rezago escolar 0.000000

yo hice dos simulaciones las cuales te las paso en el grafico, sin embargo me gustaría que me hagas algunas recomendaciones que me ayuden a complementar un poco más el trabajo porque me parece que esta muy simple la parte final de los objetivos




Impacto Contrafactual: Mejora en la Probabilidad por Reducción de Pobreza Estructural
Bogota D.C.
Caldas
Valle del Cauca
Cundinamarca
Antioquia
Risaralda
Quindio
Santander
Meta
Boyaca
Tolima
Atlantico
Casanare
Norte de Santander
Huila
Cauca
Cesar
Caqueta
Arauca
Putumayo
Guaviare
Narino
Magdalena
Bolivar
Amazonas
Sucre
Cordoba
San Andres
La Guajira
Guainia
Choco
Vaupes
Vichada
Línea Base 2024
Escenario 3 (-30% Excretas/Informalidad/Agua)
Umbral Satisfactorio (50%)
0.0
0.2
0.4
0.6
0.8
1.0
Probabilidad de Desempeño Satisfactorio